

LLM 동시성 개선 결과 보고서

600명 동시 사용 — 개선 전 / 개선 후

환경: mybook.lgacademy.com · Docker 3 replica · nginx · AI Studio 풀 · 도구: k6 · 작성일: 2026-06-22

600명 동시 사용에서 실패가 사라졌습니다.

개선 전에는 600명 중 약 94%가 HTTP 500으로 실패했습니다. 비동기 대기열(큐) 적용 후 **거절 0건, 90.2%가 결과를 정상 수신**했습니다. 다만 처리량 한계로 평균 대기 2.5분이 발생합니다.

~94%

개선 전 실패율 (600명)

0%

개선 후 거절률

90.2%

개선 후 결과 수신

0

스티키 라우팅 오류

1. 결론 요약

프로덕션에 비동기 대기열 + 동시성 게이트 + nginx 스티키 세션을 배포하고 600명 부하를 재측정했습니다. **과부하로 인한 실패(89% → 0%)가 완전히 사라졌고**, 모든 사용자가 접수(202)된 뒤 순서대로 처리되었습니다. 스티키 라우팅은 600명 부하에서도 **오류 0건**으로 정상 동작했습니다. 남은 과제는 '실패'가 아니라 '속도' — 동시 처리량 한계로 인한 대기 시간입니다.

2. 조치 내용

- 비동기 대기열**: POST 시 즉시 작업번호(jobId) 반환(202), 클라이언트가 결과를 폴링. 연결을 붙잡지 않으므로 **타임아웃 자체가 발생하지 않음** — 사용자는 줄을 서서 기다림.
- 동시성 게이트**: 업스트림 동시 호출을 복제본당 5개(×3=15)로 제한, 초과분은 대기. 과부하 500을 원천 차단.
- nginx 스티키 세션**: `hash $cookie_qrius_session consistent` — 사용자별로 같은 복제본에 고정해 폴링이 항상 자기 작업을 찾음.

3. 개선 전 / 개선 후 (600명)

지표	개선 전 (동기)	개선 후 (비동기 큐)
거절 / 실패	~94% (HTTP 500)	0% 거절
결과 수신	6.5%	90.2% (5분 내)
과부하 500	수천 건	4건
접수(202) 지연	—	p95 358ms (즉시)
스티키 라우팅 오류	—	0건

4. 응답 시간 (대기의 대가)

개선 전: 결과 수신		6.5%
개선 후: 결과 수신		90.2%

대기열은 '실패'를 '대기'로 바꿉니다. 600명이 동시 처리량 15개 파이프를 통과하므로 결과까지 **중앙값 2.5분, p95 4.7분, 최대 5.0분**이 걸립니다. 측정 마감(5분) 시점에 **55명**이 아직 대기 중이었습니다(실패가 아니라 순번 대기 — 실제 앱은 6분까지 기다림).

5. 남은 과제 (속도)

- 업스트림 한도 상향(핵심)**: AI Studio 동시 처리 한도를 ~20 이상으로 올리거나 **별도 계정** — 대기 시간을 줄이는 유일한 근본 해법.

- **입장 분산:** 600명을 수 분에 걸쳐 순차 입장시키면 순간 대기열이 크게 줄어듦.
- **큐 동시성 상황:** LLM_QUEUE_CONCURRENCY를 올릴 수 있으나 ~20 업스트림 한계 안에서만 유효(복제본당 6 → 18).
- **주의:** 이번 측정은 최경량 작업 — 실제 매거진(무거운 합성 21회)은 대기 시간이 더 김. 위 조치가 함께 필요.