

Konfirmasi Akar Masalah — Kegagalan LLM untuk 600 Pengguna

Mengapa hal ini terjadi (terkonfirmasi)

Dasar: Sweep konkurensi produksi (k6 + curl) + analisis kode · Tanggal: 2026-06-19

Kesimpulan Terkonfirmasi

Setiap langkah AI di majalah memanggil **satu akun LG AI Studio**. Akun ini hanya mampu memproses **±20 permintaan secara bersamaan**. Bila lebih dari itu datang serentak, kebanyakannya tidak diantrekan melainkan langsung ditolak dengan **500 "terjadi kesalahan"**. Aplikasi **tidak punya antrian maupun retry** untuk konkurensi ini. Maka pada 600 pengguna serentak, hanya ±20 yang berhasil, sisanya gagal.

Bukti — Sweep Konkurensi (pengukuran produksi)

Dengan menaikkan jumlah permintaan bersamaan: **hingga 20 = 100% sukses**, di atas itu penolakan (500) mulai muncul, dan **jumlah sukses berhenti di ±20**. Beban ditambah pun sukses tetap sama, kelebihan semuanya gagal.

Permintaan bersamaan	Keberhasilan	Ditolak (500)
10	100%	0
20	100%	0
25	64%	9
30	60%	12
40	40%	24
50	36%	32
60	40%	36

Mengapa rotasi 10 kunci API tidak menyelesaikannya

- **Rotasi untuk masalah lain:** Rotasi kunci membagi **kuota token (batas harian/menit)**. Masalah sekarang adalah **konkurensi** — batas yang sama sekali berbeda.
- **Rotasi bahkan tidak aktif untuk error ini:** Pada kode, perpindahan kunci hanya terjadi saat pesan batas token; 500 lain **langsung dilempar** — tanpa retry/perpindahan (aistudio.ts).
- **Andai pun pindah, percuma:** 10 kunci (LG_BOOK_01-10) berbagi **akun, token, dan alamat yang sama**. Hanya mengetuk pintu 20-konkurensi yang sama. Terbukti: beban tersebar merata ke 10 kunci pun sukses berhenti di 20 (bila per-kunci, harusnya ~200).

Analogi: Penyedia LLM ibarat **dapur yang hanya memasak 20 hidangan sekaligus**. 10 kunci hanyalah **10 kartu pembayaran** — ganti kartu (kuota token) tidak mengubah kapasitas dapur (konkurensi). 600 orang pesan serentak: 20 jadi, sisanya ditolak "dapur penuh".

Arah Perbaikan

- **Antrian sisi server (batas konkurensi):** Batasi panggilan hulu ke ±15-18 dan **antrekan** kebanyakannya — menunggu giliran, bukan gagal. (Hanya bisa di server, bukan frontend — hanya server melihat trafik semua pengguna.)
- **Retry (backoff):** 500 ini bersifat sementara — retry 2-3× dengan backoff memulihkan banyak.
- **Naikkan batas penyedia:** Minta LG AI Studio menaikkan batas konkurensi atau **akun terpisah** — satu-satunya cara benar-benar melayani >20 serentak.
- **Mitigasi frontend:** Jangan kirim banyak panggilan **paralel** per pengguna (serialkan 4 artikel bab), beri UX menunggu saat generasi.

