

원인 확정 — LLM 600명 동시 사용 실패

왜 이런 현상이 일어나는가 (확정)

근거: 프로덕션 동시성 스왑(k6 + curl) + 코드 분석 · 작성일: 2026-06-19

확정 결론

매거진의 모든 AI 단계는 하나의 LG AI Studio 계정을 통해 호출됩니다. 이 계정은 동시에 약 20건까지만 처리할 수 있습니다. 그 이상 이 한꺼번에 몰리면 초과분은 대기열에 들어가지 않고 즉시 500 "오류가 발생했습니다" 로 거절됩니다. 앱에는 이 동시성을 제어하는 대기열(큐)도, 재시도도 없습니다. 따라서 600명이 동시에 사용하면 약 20건만 성공하고 나머지는 실패합니다.

근거 — 동시성 스왑 (프로덕션 실행)

동시 요청 수를 올리며 측정한 결과: 20건까지는 100% 성공, 그 이상부터 거절(500)이 시작되고 성공 건수는 약 20에서 더 늘지 않습니다. 부하를 더 줘도 성공은 그대로, 초과분만 전부 실패합니다.

동시 요청	성공률	거절(500)
10	100%	0
20	100%	0
25	64%	9
30	60%	12
40	40%	24
50	36%	32
60	40%	36

왜 10개 API 키 로테이션으로 해결이 안 되는가

- 로테이션은 다른 문제를 위한 것: 키 로테이션은 토큰 사용량(일/분 한도)을 분산하기 위한 장치입니다. 지금 문제는 동시 처리량으로, 전혀 다른 한계입니다.
- 이 오류에는 로테이션이 작동조차 안 함: 코드상 토큰 한도 메시지일 때만 다음 키로 넘어가고, 그 외 500은 즉시 throw — 재시도·전환 없음 (aistudio.ts).
- 설령 넘어가도 소용없음: 10개 키(LG_BOOK_01~10)는 같은 계정·같은 토큰·같은 주소를 공유합니다. 같은 20 동시성 문을 두드릴 뿐입니다. 실행에서도 10키에 고루 분산했음에도 성공이 20에서 멈춥니다(키당 한도였다면 ~200이어야 함).

비유: LLM 제공자는 한 번에 20개 요리만 만드는 주방입니다. 10개 키는 결제 카드 10장일 뿐 — 카드(토큰 한도)를 바꿔도 주방(동시 처리량)은 그대로입니다. 600명이 동시에 주문하면 20개만 나오고 나머지는 "주방 꽉 참"으로 반려됩니다.

해결 방향

- 서버측 큐(동시성 상한): 업스트림 동시 호출을 약 15~18로 제한하고 초과분을 대기시킴 — 실패 대신 순번 대기. (프론트가 아닌 서버에서만 가능 — 전체 사용자 트래픽을 서버만 알기 때문.)
- 재시도(백오프): 이 500은 일시적 — 2~3회 지수 백오프 재시도로 상당수 회복.
- 제공자 한도 상황: LG AI Studio에 동시 처리 한도 상황 또는 별도 계정 요청 — 진짜로 20 이상 동시에 받는 유일한 길.
- 프론트 완화: 한 사용자가 여러 호출을 병렬로 쓰지 않기(챗터 기사 4건 직렬화), 생성 중 대기 UX.