

Laporan Uji Beban Endpoint LLM — 100 Pengguna Bersamaan

Target: LG Magazine · Lingkungan: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio 10-key pool · Model: Claude Sonnet 4.6
· Alat: k6 · Waktu jalan: ≈12:00 KST (운영 시간대 / jam aktif) · Tanggal: 2026-06-25

Endpoint LLM (pembuatan AI) **menangani** 100 pengguna bersamaan dengan baik.

Setelah penerapan antrian kerja asinkron + gerbang konkurensi, 100 pengguna yang meminta pembuatan majalah secara bersamaan tetap mencapai **tingkat keberhasilan akhir 100.0%**, dengan waktu hingga hasil median **3.6 detik**. Model saat ini adalah **Claude Sonnet 4.6**.

100.0% Keberhasilan terima (202)	100.0% Keberhasilan hasil akhir	3.6s Waktu ke hasil (median)	4.7s Waktu ke hasil (p95)
--	---	--	---

1. Ringkasan Kesimpulan

Konfigurasi saat ini mampu **menangani 100 pengguna bersamaan secara stabil**. Sebelumnya (mode sinkron), pada 50 pengguna keberhasilan 41.8% dan pada 600 pengguna anjlok ke 6.5%. Setelah **antrian asinkron + gerbang konkurensi**, 100 permintaan bersamaan mencatat keberhasilan terima dan hasil akhir sama-sama 100.0%. Kegagalan diserap menjadi penundaan singkat, bukan error.

- Keberhasilan akhir 100.0%:** 100 permintaan mencapai hasil — 0 fallback/timeout/error hulu.
- Penerimaan cepat:** POST langsung mengembalikan 202 + jobId (p95 479ms). Pengguna tidak menunggu, layar tetap berjalan.
- Penundaan hasil:** waktu ke hasil median 3.6 detik, p95 4.7 detik, maks 10.8 detik — termasuk antre gerbang.
- Gerbang konkurensi:** 5 panggilan serentak/proses × 3 replika ≈ 15, dijaga di bawah batas AI Studio hulu (~20).
- Model:** diukur pada Claude Sonnet 4.6.

2. Konfigurasi Uji

Endpoint	POST /api/v3/llm (terima) · GET /api/v3/llm/jobs (polling)
Tugas (task)	extractKeyword (panggilan LLM nyata pada pembuatan majalah)
Model	Claude Sonnet 4.6
Penyedia	Pool 10 kunci AI Studio (default produksi)
Autentikasi	Cookie sesi valid-produksi dibuat offline (loadtest-00001...100)
Pola beban	100 VU, tiba dalam 60 detik, tiap VU 1 permintaan (meniru pengguna nyata)
Cara ukur	terima (202) → polling tiap 2 detik → ukur waktu hingga hasil
Kontrol konkurensi	antrian 5/proses · gerbang AI Studio 5/proses

3. Hasil Pengukuran

Metrik	Nilai	Catatan
Jumlah permintaan	100	100 VU × 1
Keberhasilan terima (202)	100.0%	POST langsung beri jobId
Keberhasilan hasil akhir	100.0%	mencapai hasil (done)

Respons terima p95	479 ms	pengguna tak menunggu
Waktu ke hasil median	3.6 s	terima→hasil (termasuk antre)
Waktu ke hasil p95	4.7 s	
Waktu ke hasil maks	10.8 s	
Polling 404 (sticky miss)	0	0 = routing sesi normal
Error hulu (job error)	0	0 = tak ada error AI Studio
Timeout klien	0	0 = semua selesai tepat waktu

4. Dibanding Sebelumnya (Dampak Perbaikan)

Pada mode sinkron lama, panggilan LLM diproses langsung saat permintaan sehingga saat beban bersamaan menumpuk, AI Studio hulu mengembalikan error 500 per panggilan (50 pengguna 41.8%, 600 pengguna 6.5% sukses). **Antrian asinkron + gerbang konkurensi** membatasi jumlah panggilan serentak di bawah batas hulu dan mengantre kelebihanannya sebentar, **mengubah error menjadi penundaan**. Hasilnya, pada 100 pengguna bersamaan keberhasilan akhir mencapai 100.0%.

5. Rekomendasi

- **Pertahankan konfigurasi:** kelas berisi 100 orang stabil dengan setelan saat ini. Tak perlu tindakan tambahan.
- **Siapkan skala lebih besar:** di atas 600 pengguna penundaan hasil bisa memanjang — sesuaikan jumlah replika atau nilai gerbang ($\times$ replika $\leq \sim 20$) terhadap batas hulu.
- **UX indikator progres:** karena terima instan (202), gunakan indikator "sedang membuat..." agar tunggu terasa wajar.
- **Pemantauan:** lacak p95 waktu ke hasil dan panjang antrean sebagai metrik operasi untuk scale-up dini.
- **Uji skala besar:** disarankan uji tambahan skenario 300-600 pengguna bersamaan pada dini hari untuk memetakan kurva penundaan.

Batasan Pengukuran. Berdasarkan satu tugas (extractKeyword), satu kali run di jam aktif. Antrian berbasis memori per-proses (replika), sehingga terima dan polling harus dirutekan ke replika yang sama (hash sesi nginx). Pada run ini polling 404=0, memastikan routing normal.