

LLM 엔드포인트 부하 테스트 보고서 — 100명 동시 사용

대상: LG Magazine · 환경: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio 10-key pool · 모델: Claude Sonnet 4.6 · 도구: k6 · 실행 시간: ~12:00 KST (운영 시간대 / jam aktif) · 작성일: 2026-06-25

LLM(AI 생성) 엔드포인트가 100명 동시 사용을 정상적으로 처리합니다.

비동기 작업 큐 + 동시성 게이트 적용 후, 100명이 동시에 매겨진 생성을 요청해도 최종 성공률 100.0%, 결과까지 중앙값 3.6초로 완료됩니다. 모델은 현재 Claude Sonnet 4.6 입니다.

100.0%

접수 성공률 (202)

100.0%

최종 결과 성공률

3.6s

결과까지 소요 (중앙값)

4.7s

결과까지 소요 (p95)

1. 결론 요약

현재 구성은 100명 동시 사용을 안정적으로 감당합니다. 이전(동기 방식)에는 동시 50명에서 성공률 41.8%, 600명에서 6.5%로 붕괴했지만, 비동기 큐 + 동시성 게이트 도입 후 100명 동시 요청에서 접수·최종 성공 모두 100.0%를 기록했습니다. 실패가 오류 대신 짧은 대기로 흡수됩니다.

- 최종 성공률 100.0%: 100건 요청이 모두 결과까지 도달 — 폴백/타임아웃/상위 오류 0건.
- 빠른 접수: POST는 즉시 202 + jobId 반환 (p95 479ms). 사용자는 기다리지 않고 화면이 진행됨.
- 결과 지연: 결과까지 중앙값 3.6초, p95 4.7초, 최대 10.8초 — 게이트 대기 포함.
- 동시성 게이트: 프로세스당 동시 5건 × 3 레플리카 ≈ 15건으로 상위 AI Studio 한계(~20)를 넘지 않게 직렬화.
- 모델: Claude Sonnet 4.6 기준 측정.

2. 테스트 설정

엔드포인트	POST /api/v3/llm (접수) · GET /api/v3/llm/jobs (폴링)
작업(task)	extractKeyword (실제 매겨진 생성의 LLM 호출)
모델	Claude Sonnet 4.6
제공자	AI Studio 10키 풀 (운영 기본값)
인증	오프라인 발급한 운영 유효 세션 쿠키 (loadtest-00001...100)
부하 패턴	100 VU, 60초에 걸쳐 도착, 각 VU 1회 요청 (실제 사용자 모사)
측정 방식	접수(202) → 2초 간격 폴링 → 결과까지 시간(time-to-result) 측정
동시성 제어	큐 동시 5건/프로세스 · AI Studio 게이트 5건/프로세스

3. 측정 결과

지표	값	비고
요청 수	100건	100 VU × 1회
접수 성공률 (202)	100.0%	POST가 즉시 jobId 반환
최종 결과 성공률	100.0%	결과(done)까지 도달
접수 응답 p95	479 ms	사용자 대기 없음

결과까지 중앙값	3.6 s	접수→결과(큐 대기 포함)
결과까지 p95	4.7 s	
결과까지 최대	10.8 s	
폴링 404 (스티키 미스)	0건	0 = 세션 라우팅 정상
상위 오류(job error)	0건	0 = AI Studio 오류 없음
클라이언트 타임아웃	0건	0 = 마감 내 모두 완료

4. 이전 대비 (개선 효과)

이전 동기 방식에서는 LLM 호출을 요청 시점에 그대로 처리해 동시 부하가 몰리면 상위 AI Studio가 건별 500 오류를 반환했습니다(50명 41.8%, 600명 6.5% 성공). **비동기 큐 + 동시성 게이트**는 동시 호출 수를 상위 한계 이하로 직렬화하고, 초과분을 짧게 대기시켜 **오류를 대기로 전환**합니다. 그 결과 100명 동시에서 최종 성공률 100.0%를 달성했습니다.

5. 권장 사항

- **현 구성 유지:** 100명 규모 수업은 현재 설정으로 안정적. 추가 조치 불필요.
- **더 큰 규모 대비:** 600명 이상은 결과 지연이 길어질 수 있음 — 레플리카 수 또는 게이트 값($\times$ 레플리카 $\leq \sim 20$)을 상위 한계에 맞춰 조정.
- **진행 표시 UX:** 접수가 즉시(202)이므로 "생성 중..." 진행 표시로 체감 대기를 자연스럽게.
- **모니터링:** 결과까지 p95와 큐 대기 길이를 운영 지표로 추적해 한계 도달 전 선제 확장.
- **대규모 재측정:** 300·600명 동시 시나리오를 심야에 추가 측정해 결과 지연 곡선 확보 권장.

측정 한계. 단일 작업(extractKeyword) 기준, 운영 시간대 1회 실행. 큐는 프로세스(레플리카) 내 메모리 기반이므로 접수와 폴링이 같은 레플리카로 라우팅되어야 함(nginx 세션 해시). 이번 실행에서 폴링 404=0으로 라우팅 정상 확인됨.