

Laporan Hasil Uji Beban Endpoint LLM

Target: LG Magazine · Lingkungan: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio 10-key rotation pool · Alat: k6 · Waktu jalan: ≈14:00 KST (운영 시간대 / jam aktif) · Tanggal: 2026-06-19

Endpoint LLM (pembuatan AI) tidak mampu menangani 600 pengguna bersamaan.

Pada 50 pengguna bersamaan, tingkat keberhasilan sudah turun ke ±42%, dan pada 400 pengguna anjlok di bawah 5%. Penyebabnya bukan batas token harian, melainkan error 500 umum dari API AI Studio hulu saat panggilan bersamaan.

9.4%

Keberhasilan total (ramp 50→600)

18.2s

Latensi p95 (saat beban)

2.8s

Panggilan tunggal (tanpa beban)

2,110

Total permintaan

1. Ringkasan Kesimpulan

Dengan konfigurasi saat ini, pembuatan majalah AI tidak akan berjalan normal untuk kelas berisi 600 orang. Walaupun diukur dengan tugas paling ringan (extractKeyword, 80 token), tingkat keberhasilan turun tajam seiring bertambahnya pengguna bersamaan. Panggilan tunggal tanpa beban = 2,8 detik/sukses, tetapi saat konkurensi naik, penyedia hulu (AI Studio) mengembalikan 500 per permintaan.

- Kurva kapasitas:** 50 pengguna 41,8% → 200 pengguna 15,3% → 400 pengguna 4,7% → 600 pengguna 6,5% sukses. Konkurensi adalah hambatan utama.
- Sifat kegagalan:** Pesan batas token harian ("토큰 호출량") sama sekali tidak muncul (pool_exhausted=0). Yang muncul: error umum aistudio call (LG_B00K_x): 500 "terjadi kesalahan, coba lagi."
- Batas rotasi 10 kunci:** Memutar kunci tidak menambah ruang konkurensi karena API hulu sendiri mengembalikan 500 saat beban bersamaan.
- Latensi:** Saat beban, median 10 detik, p95 13-19 detik (4-7× lipat dari 2,8 detik tanpa beban).

2. Konfigurasi Uji

Endpoint	POST /api/v3/llm
Tugas (task)	extractKeyword (paling ringan, 80 token)
Penyedia	Pool rotasi 10 kunci AI Studio (default produksi)
Autentikasi	Cookie sesi valid-produksi dibuat offline (loadtest-00001...600)
Pola beban	50 → 200 → 400 → 600 VU, tahan 20 detik per tahap (run terbatas)
Model eksekusi	closed-loop (tiap VU meminta ulang 1-3 detik setelah respons)

3. Kurva Kapasitas (per pengguna bersamaan)


Tingkat keberhasilan (makin tinggi makin baik)

50 VU

41.8% Tingkat keberhasilan (makin tinggi makin baik)

200 VU

15.3% Tingkat keberhasilan (makin tinggi makin baik)



Pengguna bersamaan	Keberhasilan	Median respons	p95	Maks	Error 500 hulu
50	41.8%	9.6s	12.9s	15.6s	64
200	15.3%	10.5s	13.5s	18.0s	350
400	4.7%	13.0s	18.7s	25.4s	670
600	6.5%	10.7s	18.2s	21.6s	608

4. Pengukuran — Skenario Penggunaan Nyata (sesi penuh)

Bab 3 di atas hanya mengulang tugas paling ringan (`extractKeyword`). Pengguna nyata memanggil ± 21 tugas LLM per sesi (termasuk 7 tugas sintesis berat, masing-masing 2.200 token · 15-25 detik) secara berurutan. Berikut hasil mereproduksi seluruh alur sesi tersebut.

Sesi bersamaan	Keberhasilan panggilan	Median tugas berat	p95 tugas berat	Durasi sesi (median)
1 (unloaded baseline)	90.5%	9.5s	28.3s	3.7 min
10 concurrent	76.7%	12.3s	50.9s	4.8 min

Bahkan satu pengguna tanpa beban pun hanya 90% panggilan berhasil, sehingga sesi yang menuntaskan 21 panggilan tanpa satu kegagalan praktis tidak ada (tingkat tuntas 0%). Pada 10 sesi bersamaan saja, p95 tugas berat mencapai 51 detik — mendekati batas server (60 detik) sehingga timeout terjadi, dan satu sesi butuh ± 4.8 menit. Maka pada 600 pengguna bersamaan, pembuatan majalah praktis hampir tidak pernah selesai.

5. Analisis Penyebab Kegagalan

Kegagalan bukan dari web server (nginx/Next.js) atau autentikasi, melainkan dari API AI Studio hulu. Saat panggilan bersamaan menumpuk, tiap kunci (`LG_BOOK_1...10`) mengembalikan `500 "terjadi kesalahan"`. Ini berbeda dari habisnya kuota harian — ini **batas konkurensi/throughput sesaat**. Karena itu, menambah kunci pun kemungkinan tetap gagal bila banyak panggilan terjadi di saat yang sama.

6. Rekomendasi

- Batasi konkurensi (antrian):** Beri batas jumlah panggilan LLM aktif di level aplikasi dan antrekan sisanya — cegah stampede sesaat.
- Coba ulang (backoff):** Error 500 bersifat sementara — coba ulang 1-2× dengan exponential backoff + jitter.
- Sebar di UX:** Beri jeda antar-pengguna pada langkah pemicu generasi agar panggilan tidak menumpuk bersamaan.
- Fallback overflow:** Saat melewati batas, alihkan sebagian trafik ke mode Anthropic (`x-llm-mode=claude`).
- Ukur ulang di jam sepi:** Run ini dilakukan di jam aktif — disarankan ukur ulang dini hari untuk memisahkan batas konkurensi dari batas harian.

Batasan Pengukuran. Run terbatas (20 detik/tahap), tugas paling ringan, dan dilakukan di jam aktif. Model closed-loop lebih keras daripada kedatangan nyata, tetapi di kelas nyata pun panggilan LLM mengelompok di tahap yang sama, sehingga arah temuan tetap valid.