

LLM 엔드포인트 부하 테스트 결과 보고서

대상: LG Magazine · 환경: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio 10-key rotation pool · 도구: k6 · 실행 시각: ≈14:00 KST (운영 시간대 / jam aktif) · 작성일: 2026-06-19

LLM(AI 생성) 엔드포인트는 600명 동시 사용을 감당하지 못합니다.

동시 50명에서 이미 성공률이 약 42%로 떨어지고, 400명에서는 5% 미만으로 붕괴합니다. 원인은 일일 토큰 한도가 아니라 동시 호출 시 상위 AI Studio API가 반환하는 일반 500 오류입니다.

9.4%

전체 성공률 (50→600 램프)

18.2s

응답시간 p95 (부하 시)

2.8s

단일 호출 기준 (무부하)

2,110

총 요청 수

1. 결론 요약

현재 구성으로는 600명 규모 수업에서 AI 매겨진 생성이 정상 동작하지 않습니다. 가장 가벼운 작업(extractKeyword, 80토큰)으로 측정했음에도, 동시 사용자가 늘수록 성공률이 가파르게 하락했습니다. 무부하 단일 호출은 2.8초/정상이지만, 동시성이 올라가면 상위 제공자(AI Studio)가 건별로 500을 반환합니다.

- 용량 곡선:** 50명 41.8% → 200명 15.3% → 400명 4.7% → 600명 6.5% 성공. 동시성이 핵심 병목.
- 실패 성격:** 일일 토큰 한도("토큰 호출량") 메시지는 전혀 없었음(pool_exhausted=0). 대신 `aistudio call (LG_B00K_x): 500 "오류가 발생했습니다. 다시 시도해 주세요."` 형태의 일반 오류.
- 10키 로테이션의 한계:** 키를 돌려도 상위 API 자체가 동시 부하에서 500을 내므로 동시성 여유가 생기지 않음.
- 지연:** 부하 시 중앙값 10초, p95 13~19초 (무부하 2.8초 대비 4~7배).

2. 테스트 설정

엔드포인트	POST /api/v3/llm
작업(task)	extractKeyword (최경량, 80 토큰)
제공자	AI Studio 10키 로테이션 풀 (운영 기본값)
인증	오프라인 발급한 운영 유효 세션 쿠키 (loadtest-00001...600)
부하 패턴	50 → 200 → 400 → 600 VU, 각 단계 20초 유지 (제한 실행)
실행 모델	closed-loop (각 VU가 응답 후 1~3초 후 재요청)

3. 용량 곡선 (동시 사용자별)

성공률 (높을수록 좋음)

50 VU		41.8% 성공률 (높을수록 좋음)
200 VU		15.3% 성공률 (높을수록 좋음)
400 VU		4.7% 성공률 (높을수록 좋음)
600 VU		6.5% 성공률 (높을수록 좋음)

동시 사용자	성공률	응답 중앙값	p95	최대	상위 500 오류
50	41.8%	9.6s	12.9s	15.6s	64

200	15.3%	10.5s	13.5s	18.0s	350
400	4.7%	13.0s	18.7s	25.4s	670
600	6.5%	10.7s	18.2s	21.6s	608

4. 실측 — 실제 사용 시나리오 (전체 세션)

위 3장은 가장 가벼운 작업(extractKeyword)만 반복한 측정입니다. 실제 사용자는 한 세션에서 약 21개의 LLM 작업(그중 무거운 합성 작업 7개, 각 2,200토큰·15~25초)을 순서대로 호출합니다. 아래는 이 전체 세션 흐름을 그대로 재현해 측정한 값입니다.

동시 세션	호출 성공률	무거운 작업 중앙값	무거운 작업 p95	세션 소요(중앙값)
1 (unloaded baseline)	90.5%	9.5s	28.3s	3.7 min
10 concurrent	76.7%	12.3s	50.9s	4.8 min

무부하 단일 사용자조차 호출 성공률이 90%에 그쳐, 21개 호출을 한 번도 실패 없이 끝내는 세션은 사실상 없습니다(완주율 0%). 동시 10세션만 되어도 무거운 작업 p95가 51초로 서버 제한(60초)에 근접해 타임아웃이 발생하고, 한 세션 완주에 약 4.8분이 걸립니다. 따라서 600명 동시 사용에서는 실질적으로 매겨진 생성이 거의 완료되지 않습니다.

5. 실패 원인 분석

실패는 웹 서버(nginx/Next.js)나 인증이 아니라 상위 AI Studio API에서 발생했습니다. 동시 호출이 몰리면 개별 키(LG_BOOK_1...10)가 500 "오류가 발생했습니다" 를 반환합니다. 이는 일일 한도 소진과 다른, 동시성/순간 처리량 한계입니다. 따라서 키를 더 추가해도 같은 순간 동시 호출이 많으면 동일하게 실패할 가능성이 높습니다.

6. 권장 사항

- 동시 호출 제한(큐잉): 앱 레벨에서 동시 진행 LLM 호출 수에 상한을 두고 초과분을 큐로 직렬화 — 순간 스템피드 방지.
- 재시도(백오프): 일반 500은 일시적 — 지수 백오프 + 지터로 1~2회 재시도.
- UX 분산: 생성 트리거 단계를 사용자별로 시차를 두어 동시 호출 집중 완화.
- 오버플로 폴백: 한도 초과 시 Anthropic(claude) 모드로 일부 트래픽 우회 (x-llm-mode=claude).
- 운영 시간대 재측정: 이번 실행은 운영 시간대였음 — 심야(off-hours) 재측정으로 동시성 한계와 일일 한도를 분리 확인 권장.

측정 한계. 제한 실행(각 단계 20초)·최경량 작업·운영 시간대 조건. closed-loop는 실제 입장보다 가혹하지만, 실제 수업에서도 동일 단계에서 LLM 호출이 군집하므로 방향성은 유효합니다.