

Laporan Uji Beban Endpoint LLM — 600 Pengguna Bersamaan

Target: LG Magazine · Lingkungan: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio 10-key pool · Model: Claude Sonnet 4.6
· Alat: k6 · Waktu jalan: ≈15:00 KST (운영 시간대 / jam aktif) · Tanggal: 2026-06-25

Logika saat ini (antrian asinkron) menangani seluruh 600 pengguna bersamaan.

Meski 600 pengguna mengirim panggilan LLM bersamaan, keberhasilan terima & hasil akhir sama-sama 100.0%, dengan 0 error & 0 timeout. Konsekuensinya, waktu ke hasil memanjang — median 14.9 detik, p95 42.2 detik. Model: Claude Sonnet 4.6.

100.0% Keberhasilan terima (202)	100.0% Keberhasilan hasil akhir	14.9s Waktu ke hasil (median)	42.2s Waktu ke hasil (p95)
--	---	---	--

1. Ringkasan Kesimpulan

Konfigurasi saat ini tidak menggagalkan satu pun permintaan, bahkan pada 600 panggilan bersamaan. Antrian asinkron + gerbang konkurensi menyerap lonjakan sesaat menjadi **penundaan**, bukan **error**. Penerimaan instan (202, p95 318ms); hasil tiba lewat antrean pada median 14.9 detik · p95 42.2 detik · maks 48.5 detik. Server produksi normal sepanjang uji.

- Keberhasilan akhir 100.0%:** seluruh 600 permintaan mencapai hasil — 0 error hulu, 0 polling 404, 0 timeout klien.
- Penerimaan cepat:** POST langsung mengembalikan 202 + jobId (p95 318ms). Pengguna tak menunggu, layar berjalan.
- Penundaan hasil (harga yang dibayar):** makin tinggi konkurensi, makin lama antre — waktu ke hasil median 14.9 detik, p95 42.2 detik.
- Gerbang konkurensi:** 5/proses × 3 replika ≈ 15, dijaga di bawah batas AI Studio (~20) → error 500 hulu dicegah dari akar.
- Model:** diukur pada Claude Sonnet 4.6.

2. Konfigurasi Uji

Endpoint	POST /api/v3/llm (terima) · GET /api/v3/llm/jobs (polling)
Tugas (task)	extractKeyword (1 panggilan LLM/pengguna)
Model	Claude Sonnet 4.6
Penyedia	Pool 10 kunci AI Studio (default produksi)
Autentikasi	Cookie sesi valid-produksi dibuat offline (loadtest-00001...600)
Pola beban	600 VU, tiba dalam 60 detik, tiap VU 1 panggilan
Cara ukur	terima (202) → polling tiap 2 detik → waktu hingga hasil
Kontrol konkurensi	antrian 5/proses · gerbang AI Studio 5/proses
Prasyarat	Backlog uji sebelumnya dipastikan habis (antrean 0) sebelum run bersih

3. Hasil Pengukuran

Metrik	Nilai	Catatan
Jumlah permintaan	600	600 VU × 1
Keberhasilan terima (202)	100.0%	POST langsung beri jobId

Keberhasilan hasil akhir	100.0%	mencapai hasil (done)
Respons terima p95	318 ms	pengguna tak menunggu
Waktu ke hasil median	14.9 s	terima→hasil (termasuk antre)
Waktu ke hasil p95	42.2 s	
Waktu ke hasil maks	48.5 s	
Polling 404 (sticky miss)	0	0 = routing sesi normal
Error hulu (job error)	0	0 = tak ada error AI Studio
Timeout klien	0	0 = semua selesai dalam batas (5 mnt)

4. Dibanding 100 Pengguna (Skalabilitas)

Dibanding uji 100 pengguna dengan metode sama, walau konkurensi naik 6×, **keberhasilan tetap 100%** — hanya penundaan hasil yang bertambah. Artinya logika saat ini tidak gagal, melainkan **menyerap beban menjadi antrean**.

Pengguna bersamaan	Keberhasilan akhir	Median hasil	p95 hasil
100	100.0%	3.6s	4.7s
600	100.0%	14.9s	42.2s

5. Interpretasi — Arti Hasil Ini

Intinya: **"600 pengguna bersamaan pun tidak membuatnya rusak."** Pada mode sinkron lama, panggilan bersamaan langsung memicu error 500 AI Studio hulu; antrian asinkron kini membatasi jumlah panggilan serentak di bawah batas dan mengantre kelebihanannya hingga **semua berhasil**. Harganya adalah penundaan hasil (pada 600: median 14.9 detik, p95 42.2 detik) — masih wajar diserap dengan indikator "sedang membuat...".

6. Rekomendasi

- **Pertahankan konfigurasi:** hingga 600 panggilan bersamaan tanpa gagal. Bisa dioperasikan tanpa tindakan tambahan.
- **Bila perlu mempercepat:** naikkan jumlah replika atau nilai gerbang ($\times$ replika $\leq \sim 20$) terhadap batas hulu → penundaan hasil berkurang.
- **UX indikator progres:** karena terima instan (202), gunakan "sedang membuat..." untuk meringankan tunggu p95 42.2 detik.
- **Pemantauan:** lacak p95 waktu ke hasil dan panjang antrean sebagai metrik operasi untuk scale-up dini.

Batasan Pengukuran. Ini pengukuran konkurensi murni berbasis satu tugas (extractKeyword, 1/pengguna). Pengguna nyata memanggil ~21 tugas berurutan per sesi (termasuk sintesis berat), sehingga pengukuran skala besar dari sudut "menuntaskan seluruh majalah" (mis. 600 sesi) akan jauh lebih lama penundaannya. Laporan ini menjawab "apakah logika saat ini menangani 600 panggilan bersamaan tanpa gagal" (= ya).