

LLM 풀세션 부하 테스트 보고서 — 600명 동시 (전체 플로우)

대상: LG Magazine · 환경: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio (dual-lane: Flash + Sonnet) · 모델: Gemini 2.0 Flash + Claude Sonnet 4.5 · 도구: k6 · 실행 시각: ≈11:00 KST · 작성일: 2026-06-26

현재 구성은 600명 동시 풀세션을 대부분 처리하나, 일부 작업이 지연·실패합니다.

각 사용자가 한 세션에서 21개 LLM 작업(가벼운 한 줄 14개 → Gemini 2.0 Flash, 무거운 합성·챗터·표지 7개 → Claude Sonnet 4.5)을 순차 호출합니다. 600명 동시 기준 작업 성공률 90.5%, 세션 완주율 0.0%. 가벼운 작업 결과 중앙값 6.5초, 무거운 작업 8.7초.

0.0%

세션 완주율

90.5%

작업 성공률

6.5s

가벼운 작업 (Gemini 2.0 Flash) 중
양값

8.7s

무거운 작업 (Claude Sonnet 4.5)
중앙값

1. 결론 요약

600명 동시 풀세션에서 작업 성공률 90.5%, 세션 완주율 0.0%입니다. 가벼운 작업을 Gemini 2.0 Flash 라인으로 분리해 무거운 Claude Sonnet 4.5 라인 부담을 줄였지만, 세션당 7개의 무거운 작업이 누적되며 일부는 마감(5분) 내 결과를 받지 못했습니다. 작업 단위 성공은 높고, 세션 완주(21개 전부 성공) 기준이 더 가혹합니다.

- 듀얼 모델 라우팅: 가벼운 14개 작업 → Gemini 2.0 Flash(전용 라인), 무거운 7개 → Claude Sonnet 4.5. 병목 라인의 호출 수를 세션당 21→7개로 축소.
- 작업 성공률 90.5%: 600 세션 × 21개 = 약 21개 작업 기준.
- 세션 완주율 0.0%: 한 세션의 21개 작업이 전부 성공해야 완주 — 가장 엄격한 기준.
- 결과 지연: 가벼운 작업 중앙값 6.5초·p95 15.8초, 무거운 작업 중앙값 8.7초·p95 26.8초.
- 안정성: 폴링 404 0건 · 상위 오류 2건 · 클라이언트 타임아웃 0건.

2. 테스트 설정

엔드포인트	POST /api/v3/llm (접수) · GET /api/v3/llm/jobs (폴링)
시나리오	전체 매거진 플로우 — 세션당 21개 작업 순차 호출
듀얼 모델	가벼운 14개 → Gemini 2.0 Flash · 무거운 7개 → Claude Sonnet 4.5
제공자	AI Studio 듀얼 레인 (운영 기본값)
인증	오프라인 발급한 운영 유효 세션 쿠키 (loadtest-00001...00001)
부하 패턴	1 VU(=동시 세션), 0분에 걸쳐 도착, 각 VU 1세션
측정 방식	각 작업: 접수(202) → 2초 간격 폴링 → 결과까지 시간(time-to-result)
작업당 마감	300초(5분) 내 미완료 시 실패 처리
사전 조건	운영 큐 백로그 소진 확인 후 깨끗하게 실행

3. 측정 결과

지표	값	비고
시작된 세션	1개	1 VU × 1세션

세션당 작업 수	21개	가벼운 14 + 무거운 7
작업 성공률	90.5%	개별 작업이 결과(done) 도달
세션 완주율	0.0%	21개 작업 전부 성공
총 요청 수	117건	접수 + 폴링 합계
접수 응답 p95	142 ms	POST 즉시 jobId 반환
가벼운 작업 중앙값 (Gemini 2.0 Flash)	6.5 s	한 줄 L-OWL 작업
가벼운 작업 p95	15.8 s	
무거운 작업 중앙값 (Claude Sonnet 4.5)	8.7 s	합성·챗터·표지
무거운 작업 p95	26.8 s	
세션 전체 소요 중앙값	3.5 분	21개 작업 + 생각 시간 포함
세션 전체 소요 p95	3.5 분	
폴링 404 (스티키 미스)	0건	0 = 세션 라우팅 정상
상위 오류 (job error)	2건	AI Studio 처리 오류
클라이언트 타임아웃	0건	마감(5분) 초과

4. 모델 라인별 비교

듀얼 모델 라우팅의 효과를 라인별로 비교합니다. 가벼운 작업은 Gemini 2.0 Flash 전용 라인에서 빠르게 처리되고, 무거운 합성 작업만 Claude Sonnet 4.5 라인을 거칩니다.

모델 라인	세션당 작업	결과 중앙값	결과 p95
Gemini 2.0 Flash (가벼움)	14개	6.5s	15.8s
Claude Sonnet 4.5 (무거움)	7개	8.7s	26.8s

5. 해석 — 이 결과의 의미

가벼운 작업을 Gemini 2.0 Flash로 분리한 효과로 직전(듀얼 모델 도입 전)의 전면 포화는 해소됐습니다. 다만 600명 풀세션에서는 세션당 7개의 Claude Sonnet 4.5 작업이 누적돼 일부가 마감 내 완료되지 못합니다. 무거운 라인의 처리량(레플리카·게이트)이 다음 병목입니다.

6. 권장 사항

- 무거운 라인 확장: 레플리카 또는 게이트 값($\times$ 레플리카 $\leq$ 상위 한계)을 상향해 Claude Sonnet 4.5 처리량 증대.
- 마감 상황 검토: 무거운 작업 p95(26.8초) 대비 작업당 마감(300초)이 충분한지 점검.
- 진행 표시 UX: "생성 중..." 표시로 대기 흡수.

측정 한계. 전체 매거진 플로우(세션당 21개 작업)를 1명이 동시에 진행하는, 가장 무거운 시나리오입니다. 실제 사용자는 작업 사이에 더 긴 읽기·입력 시간이 있어 동시 부하가 분산되므로, 본 테스트는 보수적(최악 근접) 상한입니다. 듀얼 모델 라우팅(가벼움→Gemini 2.0 Flash, 무거움→Claude Sonnet 4.5)은 운영 기본값 그대로 적용됐습니다.