

부하 테스트 결과 보고서 — 동시 100명 ~ 600명

앱: LG 매거진 · 환경: 운영 서버 · 도구: k6 · 작성일: 2026-06-08 · 대상: 개발팀

부하가 6배 늘어도 응답 시간은 거의 그대로입니다. 동시 600명을 여유 있게 처리합니다.

실제 사용자 세션을 동시 100명에서 600명까지 늘리며 측정했습니다. 전 구간에서 성공률은 약 100%를 유지했고, 응답 시간은 거의 변하지 않았습니다 — 홈 약 130ms, 앱 내 이동 약 265ms.

99.83%

성공률 @ 600명

135ms

이동 p95 @ 600 (100부터 평탄)

135ms

홈 p95 @ 600

13,188

완료 세션 (600 실행)

1. 이 스트레스 테스트에 대하여

스트레스(부하) 테스트는 많은 사람이 한꺼번에 사용할 때 앱이 빠른 속도를 유지하는지, 그리고 안정적인지를 측정합니다. 실제 600명을 동시에 접속시키는 대신, 널리 쓰이는 오픈소스 부하 테스트 도구 k6로 수백 명의 동시 사용자가 실제 HTTP 요청을 운영 사이트에 보내는 상황을 시뮬레이션 하고, 각 가상 사용자의 체감 값을 기록했습니다.

각 가상 사용자는 실제 독자처럼 매거진을 엽니다. 페이지·이미지·폰트·인트로 오디오를 받는 첫 "콜드 방문" 후, 캐시된 상태의 빠른 "웜" 경로로 챗터를 이동하며, 실제 사람이 읽듯 동작 사이에 2~5초씩 멈춥니다.

점진적 입장 모델을 사용했습니다 — 모두가 같은 순간이 아니라 짧은 시간에 걸쳐 입장하여 실제 수업이 차오르는 방식을 모사합니다. 이를 운영 서버(라이브)에 대해 6단계(동시 100·200·300·400·500·600명)로 수행하고, 각 단계의 성공률·응답시간(p95)·처리량을 측정했습니다.

항목	내용
도구	k6 — 오픈소스 부하 테스트 도구 (실제 HTTP, 스크립트 가상 사용자)
대상	운영 서버 (라이브)
부하 모델	점진적 입장 → 피크 유지 (수업 입장 모사)
가상 사용자별	콜드 첫 방문 → 웜 챗터 이동, 2~5초 생각시간
테스트 단계	동시 100 / 200 / 300 / 400 / 500 / 600명
측정 항목	성공률, 응답시간(p95), 처리량

범위: 본 테스트는 웹 앱과 페이지 제공 계층을 대상으로 합니다. AI 매거진 생성은 실행하지 않으므로 AI 토큰을 소모하지 않습니다 — AI 처리량은 운영에 이미 적용된 10개 키 로테이션이 별도로 담당합니다.

2. 결과 — 100명 → 600명

동시접속	요청수	성공률	홈 페이지 (p95)	앱 내 이동 (p95)	웜 사이클 (p95)	첫 방문 (p95)	처리량
100명	4,432	100%	132 ms	131 ms	260 ms	16.5초	58.4 Mbps
200명	10,294	100%	133 ms	132 ms	262 ms	19.2초	89.8 Mbps
300명	17,347	99.98%	134 ms	134 ms	265 ms	21.8초	111.5 Mbps
400명	25,438	99.96%	159 ms	135 ms	267 ms	25.6초	122.4 Mbps
500명	36,850	99.9%	134 ms	134 ms	265 ms	21.3초	137.7 Mbps

600명	48,565	99.83%	135 ms	135 ms	267 ms	20.9초	147.3 Mbps
------	--------	--------	--------	--------	--------	-------	------------

p95 = 95번째 백분위수: 요청의 95%가 이 시간 이내였음을 의미 (평균보다 엄격하고 정직한 지표).

3. 표 읽는 법

성공률 — 약 100% 유지

600명에서도 첫 시도 실패는 0.17%에 불과. 사실상 오류 없음.

홈 · 앱 내 이동(p95) — 평탄

가장 중요한 값, 즉 서버 자체 응답 시간입니다. 100명에서 600명까지 거의 변하지 않습니다(약 130ms, 265ms). 부하가 늘어도 **느려지지 않는다**는 뜻이며, 여유가 충분합니다.

첫 방문(p95) — 유일하게 증가하는 항목

처음 매거진을 열 때 브라우저가 이미지·폰트·인트로 오디오를 받습니다. 이 다운로드가 가장 무거운 순간이며 대역폭에 좌우됩니다. **사용자당 1회성 비용**이고, 이후 모든 페이지는 빠른 "읽" 경로입니다. (이 값은 단일 테스트 PC의 인터넷 회선에도 일부 영향을 받으므로, 실제 서버에서의 첫 방문 경험은 표시값보다 나쁘지 않습니다.)

처리량 — 매끄럽게 증가

접속자 수에 비례해 증가(58 → 147.3 Mbps), 가용 네트워크 용량 내에서 여유.

4. 의미

동시 600명은 여유 있게 처리되며, 추가 여유도 충분합니다. 전 구간에서 응답 시간이 평탄하고 오류는 사실상 0%입니다. 목요일 수업을 위해 서빙 계층에서 바꿀 것은 없습니다.

관리할 것은 첫 방문 다운로드 집중뿐입니다. 600명이 정확히 같은 몇 초에 매거진을 열면 무거운 첫 로딩이 한꺼번에 발생합니다. 입장을 1~2분에 걸쳐 분산하면 매끄럽게 유지됩니다. 이미 적용한 자산 경량화도 이 비용을 줄여줍니다.

5. 목요일(600명) 권장 사항

- **입장 분산:** 가능하면 1~2분에 걸쳐 입장 — 동시 첫 로딩 완화.
- **모니터링:** 수업 시작 시각에 정상 여부 확인.
- **용량 변경 불필요:** 위 수치는 운영 서버 실측이며 이미 통과.

생성일 2026-06-08 · 점진적 입장 부하 테스트 (100~600명) · 데이터: loadtest/summary-grad-*.json · 단일 클라이언트에서 실행했으므로 첫 방문 시간·처리량은 서버 실제 한계 대비 보수적으로 측정됨.