

Laporan Uji Beban API LLM — 600 Pengguna Bersamaan

Target: LG Magazine · Lingkungan: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio (dual-lane: Flash + Sonnet) · Model: Gemini 2.0 Flash (light lane) · Alat: k6 · Waktu eksekusi: ≈18:40 KST (16:40 WIB) · Tanggal: 2026-07-08

Endpoint LLM (pembuatan AI) menangani 600 permintaan bersamaan dengan baik.

Skenario burst: 600 pengguna tiba dalam 60 detik, masing-masing mengirim 1 permintaan pembuatan LLM (terima → polling → hasil). Keberhasilan akhir 100.0%, waktu ke hasil median 6.9 dtk · p95 32.4 dtk. Tugas ini (extractKeyword) dirutekan ke jalur Gemini 2.0 Flash (light lane) pada arsitektur dual-lane.

100.0%	100.0%	6.9s	32.4s
Keberhasilan terima (202)	Keberhasilan hasil akhir	Waktu ke hasil (median)	Waktu ke hasil (p95)

1. Ringkasan Kesimpulan

Pada burst 600 pengguna bersamaan: terima 100.0%, keberhasilan akhir 100.0%. Antrean asinkron menyerap lonjakan sebagai antrean, bukan error, dan sejak dual-model tugas ringan diproses di jalur khusus Gemini 2.0 Flash (light lane). Dibanding pengukuran Juni (jalur tunggal Sonnet, median 14.9 dtk), median kali ini 6.9 dtk.

- Keberhasilan akhir 100.0%: dari 600 permintaan — polling 404 0 · error upstream 0 · timeout 0.
- Penerimaan cepat: POST langsung mengembalikan 202 + jobId (p95 463ms). Pengguna tidak menunggu, layar tetap berjalan.
- Latensi hasil: median 6.9 dtk · p95 32.4 dtk · maks 259.6 dtk — termasuk antre.
- Gerbang konkurensi: 5/proses × 3 replika ≈ 15, dijaga di bawah batas upstream.
- Model: diukur pada Gemini 2.0 Flash (light lane) (default produksi dual-lane).

2. Konfigurasi Pengujian

Endpoint	POST /api/v3/llm (terima) · GET /api/v3/llm/jobs (polling)
Tugas (task)	extractKeyword — 1 tugas LLM ringan nyata per pengguna
Jalur model	Gemini 2.0 Flash (light lane) — routing otomatis dual-lane
Provider	AI Studio dual-lane (default produksi)
Autentikasi	Cookie sesi valid-produksi diterbitkan offline (loadtest-00001...00600)
Pola beban	600 VU, tiba dalam 60 detik, tiap VU 1 permintaan (simulasi burst)
Pengukuran	terima (202) → polling tiap 2 dtk → time-to-result
Tenggat per tugas	Gagal jika tidak selesai dalam 300 dtk (5 menit)
Prasyarat	Backlog antrean produksi dipastikan kosong sebelum eksekusi

3. Hasil Pengukuran

Metrik	Nilai	Catatan
Jumlah permintaan	600	600 VU × 1

Keberhasilan terima (202)	100.0%	POST langsung beri jobId
Keberhasilan hasil akhir	100.0%	mencapai hasil (done)
Respons terima p95	463 ms	pengguna tak menunggu
Waktu ke hasil median	6.9 dtk	terima→hasil (termasuk antre)
Waktu ke hasil p95	32.4 dtk	
Waktu ke hasil maks	259.6 dtk	
Polling 404 (sticky miss)	0	0 = routing sesi normal
Error upstream (job error)	0	error pemrosesan AI Studio
Timeout klien	0	melampaui tenggat 5 menit

4. Perbandingan dengan Pengukuran Sebelumnya

Mode sinkron awal runtuh pada 600 pengguna bersamaan (keberhasilan 6.5%). Setelah antrean asinkron (25 Juni, jalur tunggal Sonnet): 100% berhasil, median 14.9 dtk, p95 42.2 dtk. Pada pengukuran kali ini (dual-lane), tugas ringan dipisah ke jalur Gemini 2.0 Flash (light lane): **keberhasilan 100.0% · median 6.9 dtk · p95 32.4 dtk**.

5. Rekomendasi

- **Pertahankan konfigurasi:** burst 600 pengguna bersamaan tertangani dengan setelan saat ini.
- **UX indikator progres:** karena terima instan (202), gunakan indikator "sedang membuat..." agar tunggu terasa wajar.
- **Pemantauan:** lacak p95 waktu ke hasil dan panjang antrean sebagai metrik operasional.
- **Catatan alur penuh:** beban sesi lengkap (23 tugas) diukur lewat uji full-flow terpisah — pengukuran parsial (11 menit) menunjukkan keberhasilan tugas 99,4%.

Batasan Pengukuran. Berdasarkan satu tugas ringan (extractKeyword), satu kali eksekusi — latensi tugas sintesis berat (jalur Sonnet) di luar cakupan uji ini. Antrean berbasis memori per-proses (replika), sehingga terima dan polling harus dirutekan ke replika yang sama (hash sesi ngxin); polling 404=0 mengonfirmasi routing.