

LLM API 부하 테스트 보고서 — 600명 동시 사용자

대상: LG Magazine · 환경: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio (dual-lane: Flash + Sonnet) · 모델: Gemini 2.0 Flash (light lane) · 도구: k6 · 실행 시각: ≈18:40 KST (16:40 WIB) · 작성일: 2026-07-08

LLM(AI 생성) 엔드포인트가 600명 동시 요청을 정상적으로 처리합니다.

600명이 60초 안에 도착해 각자 1건의 LLM 생성 요청(접수 → 폴링 → 결과)을 보내는 버스트 시나리오입니다. 최종 성공률 100.0%, 결과까지 중앙값 6.9초·p95 32.4초. 해당 작업(extractKeyword)은 듀얼 레인 중 Gemini 2.0 Flash (light lane) 라인으로 라우팅됩니다.

100.0%

접수 성공률 (202)

100.0%

최종 결과 성공률

6.9s

결과까지 소요 (중앙값)

32.4s

결과까지 소요 (p95)

1. 결론 요약

600명 동시 버스트에서 접수 100.0%, 최종 성공 100.0%. 비동기 큐가 순간 폭주를 오류 대신 대기로 흡수하고, 듀얼 모델 도입 후 가벼운 작업은 Gemini 2.0 Flash (light lane) 전용 라인에서 처리됩니다. 6월 단일 레인(Sonnet) 측정의 중앙값 14.9초 대비 이번 중앙값은 6.9초입니다.

- 최종 성공률 100.0%: 600건 요청 기준 — 폴링 404 0건 · 상위 오류 0건 · 타임아웃 0건.
- 빠른 접수: POST는 즉시 202 + jobId 반환 (p95 463ms). 사용자는 기다리지 않고 화면이 진행됨.
- 결과 지연: 중앙값 6.9초 · p95 32.4초 · 최대 259.6초 — 큐 대기 포함.
- 동시성 게이트: 프로세스당 5건 × 3 레플리카 ≈ 15건으로 상위 한계 이하 직렬화.
- 모델: Gemini 2.0 Flash (light lane) 기준 측정 (듀얼 레인 운영 기본값).

2. 테스트 설정

엔드포인트	POST /api/v3/llm (접수) · GET /api/v3/llm/jobs (폴링)
작업(task)	extractKeyword — 가벼운 실제 LLM 작업 1건/사용자
모델 라인	Gemini 2.0 Flash (light lane) — 듀얼 레인 자동 라우팅
제공자	AI Studio 듀얼 레인 (운영 기본값)
인증	오프라인 발급한 운영 유효 세션 쿠키 (loadtest-00001...00600)
부하 패턴	600 VU, 60초에 걸쳐 도착, 각 VU 1회 요청 (버스트 모사)
측정 방식	접수(202) → 2초 간격 폴링 → 결과까지 시간(time-to-result)
작업당 마감	300초(5분) 내 미완료 시 실패 처리
사전 조건	운영 큐 백로그 소진 확인 후 실행

3. 측정 결과

지표	값	비고
요청 수	600건	600 VU × 1회
접수 성공률 (202)	100.0%	POST가 즉시 jobId 반환
최종 결과 성공률	100.0%	결과(done)까지 도달

접수 응답 p95	463 ms	사용자 대기 없음
결과까지 중앙값	6.9 s	접수→결과(큐 대기 포함)
결과까지 p95	32.4 s	
결과까지 최대	259.6 s	
폴링 404 (스티키 미스)	0건	0 = 세션 라우팅 정상
상위 오류(job error)	0건	AI Studio 처리 오류
클라이언트 타임아웃	0건	마감(5분) 초과

4. 이전 측정과 비교

초기 동기 방식은 600명 동시에서 성공률 6.5%로 붕괴했고, 비동기 큐 도입(6월 25일, 단일 레인 Sonnet) 후 100% 성공·중앙값 14.9초·p95 42.2초를 기록했습니다. 이번 측정(듀얼 레인)에서는 가벼운 작업이 Gemini 2.0 Flash (light lane) 라인으로 분리되어 **성공률 100.0% · 중앙값 6.9초 · p95 32.4초**입니다.

5. 권장 사항

- **현 구성 유지:** 600명 동시 버스트를 현재 설정이 감당합니다.
 - **진행 표시 UX:** 접수가 즉시(202)이므로 "생성 중..." 진행 표시로 체감 대기를 자연스럽게.
 - **모니터링:** 결과까지 p95와 큐 대기 길이를 운영 지표로 추적.
 - **풀 플로우 참고:** 전체 세션(23개 작업) 부하는 별도 풀 플로우 테스트로 측정 — 부분 실측(11분)에서 작업 성공률 99.4% 확인.
- 측정 한계.** 단일 가벼운 작업(extractKeyword) 기준 1회 실행 — 무거운 합성(Sonnet 라인) 작업의 지연은 본 테스트 범위 밖입니다. 큐는 프로세스(레플리카) 내 메모리 기반이므로 접수와 폴링이 같은 레플리카로 라우팅되어야 하며(nginx 세션 해시), 폴링 404=0건으로 라우팅 상태를 확인했습니다.