

LLM 엔드포인트 부하 테스트 보고서 — 600명 동시 사용

대상: LG Magazine · 환경: mybook.lgacademy.com · Next.js · Docker 3 replica · nginx · AI Studio 10-key pool · 모델: Claude Sonnet 4.6 · 도구: k6 · 실행 시간: ~15:00 KST (운영 시간대 / jam aktif) · 작성일: 2026-06-25

현재 로직(비동기 큐)이 600명 동시 사용을 전부 처리합니다.

600명이 동시에 LLM 호출을 보내도 접수·최종 성공률 모두 100.0%, 오류·타임아웃 0건입니다. 다만 동시성이 큰 만큼 결과까지 시간이 늘어납니다 — 중앙값 14.9초, p95 42.2초. 모델은 Claude Sonnet 4.6.

100.0%

접수 성공률 (202)

100.0%

최종 결과 성공률

14.9s

결과까지 (중앙값)

42.2s

결과까지 (p95)

1. 결론 요약

현재 구성은 600명 동시 호출에서도 한 건도 실패하지 않았습니다. 비동기 큐 + 동시성 게이트가 순간 폭주를 오류 대신 대기로 흡수했습니다. 접수는 즉시 (202, p95 318ms) 이뤄지고, 결과는 큐를 거쳐 중앙값 14.9초·p95 42.2초·최대 48.5초에 도착했습니다. 운영 서버는 전 구간 정상이었습니다.

- 최종 성공률 100.0%: 600건 요청 전부 결과까지 도달 — 상위 오류 0, 폴링 404 0, 클라이언트 타임아웃 0.
- 빠른 접수: POST는 즉시 202 + jobId 반환 (p95 318ms). 사용자는 기다리지 않고 화면 진행.
- 결과 지연(대기): 동시성이 클수록 큐 대기가 늘어 결과까지 중앙값 14.9초, p95 42.2초.
- 동시성 게이트: 프로세스당 5건 × 3 레플리카 ≈ 15건으로 상위 AI Studio 한계(~20)를 넘지 않게 직렬화 → 상위 500 오류 원천 차단.
- 모델: Claude Sonnet 4.6 기준 측정.

2. 테스트 설정

엔드포인트	POST /api/v3/llm (접수) · GET /api/v3/llm/jobs (폴링)
작업(task)	extractKeyword (LLM 호출 1건/사용자)
모델	Claude Sonnet 4.6
제공자	AI Studio 10키 풀 (운영 기본값)
인증	오프라인 발급한 운영 유효 세션 쿠키 (loadtest-00001...600)
부하 패턴	600 VU, 60초에 걸쳐 도착, 각 VU 1회 호출
측정 방식	접수(202) → 2초 간격 폴링 → 결과까지 시간(time-to-result)
동시성 제어	큐 5건/프로세스 · AI Studio 게이트 5건/프로세스
사전 조건	직전 테스트 백로그 완전 소진(큐 0) 확인 후 깨끗하게 실행

3. 측정 결과

지표	값	비고
요청 수	600건	600 VU × 1회
접수 성공률 (202)	100.0%	POST가 즉시 jobId 반환
최종 결과 성공률	100.0%	결과(done)까지 도달

접수 응답 p95	318 ms	사용자 대기 없음
결과까지 중앙값	14.9 s	접수→결과(큐 대기 포함)
결과까지 p95	42.2 s	
결과까지 최대	48.5 s	
폴링 404 (스티키 미스)	0건	0 = 세션 라우팅 정상
상위 오류(job error)	0건	0 = AI Studio 오류 없음
클라이언트 타임아웃	0건	0 = 마감(5분) 내 모두 완료

4. 100명 대비 (확장성)

같은 방식의 100명 테스트와 비교하면, 동시성이 6배로 늘어도 **성공률은 100%로 동일**하고 결과 지연만 증가합니다. 즉 현재 로직은 실패하지 않고 대기로 부하를 흡수합니다.

동시 사용자	최종 성공률	결과 중앙값	결과 p95
100	100.0%	3.6s	4.7s
600	100.0%	14.9s	42.2s

5. 해석 — 이 결과의 의미

"600명이 동시에 써도 깨지지 않는다"가 핵심입니다. 이전 동기 방식에서는 동시 호출이 상위 AI Studio 500 오류로 직결됐지만, 현재 비동기 큐는 동시 호출 수를 한계 이하로 직렬화하고 초과분을 대기시켜 **전부 성공**으로 끝냅니다. 비용은 결과 지연(600명에서 중앙 14.9초, p95 42.2초)이며, "생성 중..." 진행 표시로 자연스럽게 흡수 가능한 수준입니다.

6. 권장 사항

- **현 구성 유지:** 600명 동시 호출까지 무실패. 추가 조치 없이 운영 가능.
 - **지연 단축이 필요하면:** 레플리카 수 또는 게이트 값($\times$ 레플리카 $\leq \sim 20$)을 상위 한계에 맞춰 상향 → 결과 지연 감소.
 - **진행 표시 UX:** 접수가 즉시(202)이므로 "생성 중..." 표시로 p95 42.2초 대기를 체감 완화.
 - **모니터링:** 결과까지 p95와 큐 길이를 운영 지표로 추적해 한계 도달 전 선제 확장.
- 측정 한계.** 단일 작업(extractKeyword, 1건/사용자) 기준의 순수 동시성 측정입니다. 실제 한 사용자는 한 세션에서 ~21개 작업(무거운 합성 포함)을 순차 호출하므로, 전체 매거진 완주 관점의 대규모(예: 600 세션) 측정은 결과 지연이 훨씬 길어집니다. 본 보고서는 "현재 로직이 600 동시 호출을 실패 없이 처리 하는가"에 대한 답입니다(=예).